DATAHACK UNIVAG 2026

Análise da estrutura e dos caminhos de ETL

Rota do Diploma

RECORTE PRINCIPAL	Mato Grosso, CO_UF = 51
BANCO PROPOSTO	PostgreSQL
DATA DA ANÁLISE	10 de outubro de 2026

Registros perfilados nos arquivos

2.409.764
Censo: linhas nacionais de cursos

1.403.065
Trajetória: linhas nacionais

94.545
Qualidade: registros válidos

1.629.330
IBGE: observações de MT e da UF

Recomendação: Python + PostgreSQL

Processamento em lote, com adaptadores por fonte e transformações relacionais no banco.

As contagens, fórmulas e relações descritas foram verificadas nos arquivos. O modelo SQL e as etapas de criação e carga do PostgreSQL são propostas, sem execução em um servidor de banco de dados.

Relatório técnico sobre as bases oficiais do desafio

Sumário

Estrutura das fontes, resultados verificados e proposta de implementação.

1. Decisão recomendada . . . 3

2. O que foi realmente examinado . . . 3

3. Censo da Educação Superior . . . 4

4. Indicadores de trajetória . . . 6

5. CPC, Enade, IDD e IGC . . . 9

6. IBGE . . . 10

7. Relações possíveis e perdas de cobertura . . . 13

8. Modelo PostgreSQL proposto . . . 14

9. Três caminhos de execução . . . 15

10. Fluxo detalhado do caminho recomendado . . . 16

11. Reprocessamento, revisões e publicação . . . 17

12. Produtos para as perguntas do desafio . . . 18

13. Controles de qualidade e decisões em caso de falha . . . 20

14. Desempenho e operação . . . 21

15. Ordem prática de implementação . . . 21

16. Conteúdo dos anexos . . . 22

17. Fontes e documentação . . . 22

DataHack UNIVAG 2026, Rota do Diploma. Recorte principal: Mato Grosso, código IBGE 51. Banco proposto: PostgreSQL.

Análise realizada em 10/10/2026 sobre os arquivos efetivamente baixados. Este documento distingue resultados medidos nos arquivos de recomendações para implementação. O modelo SQL anexado é uma proposta e não foi executado em um servidor PostgreSQL. Nenhum arquivo original foi alterado.

1. Decisão recomendada

Adotar um processo híbrido de ETL e ELT: Python interpreta ZIP, CSV, XLSX e JSON, preserva os arquivos originais e prepara o recorte necessário. O PostgreSQL recebe os registros por carga em lote e executa as transformações relacionais, reconciliações e agregações. O dashboard consulta tabelas de apresentação ou recebe exportações dessas tabelas.

A maior dificuldade deste conjunto está em harmonizar grãos, geografias, períodos e populações. Não existe uma única tabela de alunos que possa reunir todas as fontes. Os arquivos públicos fornecidos permitem análise de cursos, coortes, instituições e municípios. Não permitem identificar trajetórias individuais, deduplicar pessoas entre cursos ou treinar um modelo individual de risco com rótulos observados.

Começar com Python, SQL versionado e PostgreSQL. Acrescentar dbt se houver necessidade de organizar muitos modelos SQL. Acrescentar Airflow quando existirem atualização recorrente, dependências operacionais e reprocessamentos que justifiquem sua manutenção. A frequência das fontes é anual ou por edição, com revisões posteriores. Um fluxo em lote atende ao desafio.

2. O que foi realmente examinado

Foram lidos os oito CSVs nacionais do Censo, as seis planilhas nacionais de trajetória, as abas principais das 14 planilhas de qualidade, os dicionários incluídos nos arquivos, as notas informativas do Censo, os metadados e os sete CSVs completos do IBGE em MT. As perguntas e restrições do evento foram extraídas da apresentação enviada.

O inventário contém 24 arquivos INEP que precisam ser processados: seis ZIPs de trajetória, quatro ZIPs do Censo e 14 XLSX de qualidade. As 14 cópias ODS externas e as cópias ODS internas das trajetórias ficam preservadas como originais, mas não entram novamente na carga. Os arquivos de lock do Excel, Thumbs.db, notas, formulários e documentação também não são fatos analíticos.

Foram perfilados 2.409.764 registros nacionais do cadastro de cursos do Censo, 1.403.065 registros nacionais da trajetória, 94.545 registros válidos das abas principais de qualidade e 1.629.330 observações do IBGE. As contagens de registros do Censo não representam quantidade de cursos: o mesmo curso EAD aparece em várias localidades.

As verificações de contagens, fórmulas e cruzamentos descritas adiante foram realizadas nos recortes extraídos, sem carregar um banco. As verificações de unicidade das chaves

candidatas também abrangeram os registros nacionais do Censo, da trajetória e das planilhas de qualidade.

3. Censo da Educação Superior

3.1 Volume e evolução do leiaute

Ano	Linhas nacionais de cursos	Linhas MT	Códigos de curso MT	Colunas de cursos	Linhas presenciais MT	Linhas EAD MT
2021	444.786	12.278	2.737	200	745	11.533
2022	573.019	15.059	3.234	200	785	14.274
2023	671.610	17.022	3.631	202	813	16.209
2024	720.349	18.315	3.890	223	826	17.489

O recorte MT contém 62.674 linhas ao longo dos quatro anos. Há três registros de cursos sequenciais por ano. Os indicadores de graduação devem aplicar `TP_NIVEL_ACADEMICO = 1`, resultando em 62.662 linhas no conjunto 2021 a 2024. Não eliminar os cursos sequenciais da camada original.

Os CSVs nacionais de cursos somam aproximadamente 1,436 GB descompactados. O ZIP de 2024 armazena os CSVs sem compressão, enquanto os anos anteriores usam compressão. Seu tamanho de download muito maior não corresponde a um crescimento equivalente no número de linhas. Isso favorece leitura em fluxo e processamento em blocos, sem abrir tudo em memória.

Os CSVs foram lidos integralmente com separador `;` e codificação `cp1252`. Os arquivos preparados devem usar UTF-8. A leitura precisa declarar o tipo das colunas identificadoras, preservando códigos e evitando inferências automáticas.

Mudanças concretas:

Transição	Mudança observada	Tratamento
IES 2021 para 2022	Nome muda de `MICRODADOS_CADASTRO_IES_2021.CSV` para `MICRODADOS_ED_SUP_IES_2022.CSV`	Descobrir membro por família e sufixo, com validação de cabeçalho
Cursos 2022 para 2023	Entram `IN_COMUNITARIA` e `IN_CONFESSIONAL`; muda a ordem de algumas colunas	Mapear pelo nome, nunca pela posição
Cursos 2023 para 2024	Entram 24 colunas de reservas de vagas; saem `QT_ING_RVETNICO`, `QT_MAT_RVETNICO` e `QT_CONC_RVETNICO`	Preservar a taxonomia de cada ano; não presumir equivalência entre categorias

Transição	Mudança observada	Tratamento
IES 2021 para 2022	Saem `CO_PROJETO`, `CO_LOCAL_OFERTA` e `NO_LOCAL_OFERTA`	Tratar como ausência estrutural de campo nos anos seguintes
Geografia nacional	2022 utiliza código `0` em registros sem localização; outros anos usam vazio	Normalizar ausência segundo dimensão, preservando o valor original
Código CINE	Os 62.674 registros MT contêm aspas literais no código de rótulo	Remover apenas o envoltório de aspas e validar sete caracteres alfanuméricos

O rótulo CINE deve permanecer texto. Códigos como `0732E01` não são números nem notação científica. A nota do INEP explica por que esses códigos receberam proteção contra interpretação automática pelo Excel.

3.2 A dimensão geográfica do EAD define o grão

`TP_DIMENSAO` tem quatro categorias documentadas:

Código	Significado	Uso no ETL
1	Cursos presenciais ofertados no Brasil	Oferta e vínculos com localização
2	Cursos a distância ofertados no Brasil	Distribuição geográfica de vínculos; preservar localidade
3	Cursos a distância com dimensão de dados somente Brasil	Oferta nacional; não atribuir vagas a MT automaticamente
4	Cursos a distância ofertados por instituições brasileiras no exterior	Preservar no original e manter fora do recorte MT

No recorte MT existem apenas dimensões 1 e 2. Nos quatro anos, a chave `(ano, CO_CURSO, CO_MUNICIPIO)` não apresentou duplicações. A chave somente `(ano, CO_CURSO)` perde a localidade e apresenta 9.541, 11.825, 13.391 e 14.425 linhas adicionais, respectivamente.

Para preservar também o contexto nacional e a versão de cada fonte, a chave proposta é `(dataset_id, ano, TP_DIMENSAO, CO_CURSO, localidade_normalizada)`. `CO_IES` permanece um atributo validado. Se houver mais de uma instituição por curso e ano em uma nova edição, isso exige investigação, não escolha arbitrária da primeira linha.

Nos registros EAD de MT, os zeros nas vagas e na quantidade oficial de cursos decorrem da organização da base. Não significam ausência de oferta EAD. As vagas nacionais estão na dimensão 3 e não podem ser distribuídas por município a partir desses campos. O bônus de vagas por jovens é presencial e evita esse problema.

Não transformar a observação de zeros em uma regra universal que apague números: a dimensão 2 nacional de 2024 contém exceções em registros sem localização. O contrato deve sinalizar essas exceções e preservar a fonte.

3.3 Instituições com sede fora de MT

Os registros MT fazem referência a 157, 165, 168 e 170 instituições nos quatro anos. Destas, 88, 94, 97 e 97 têm sede fora de MT. Todos os códigos referenciados foram encontrados nos cadastros nacionais de IES do ano correspondente.

Carregar o cadastro nacional de IES, que tem apenas cerca de 2.600 linhas por ano, ou selecionar todas as instituições referenciadas pelo recorte de cursos. Filtrar esse cadastro por `CO_UF_IES = 51` antes do relacionamento elimina parte relevante do EAD. Distinguir sempre UF da sede institucional e UF informada para o registro do curso.

3.4 O que representam as medidas

`QT_MAT` soma vínculos nas situações cursando e formado, conforme o dicionário. Não é uma contagem exclusiva de estudantes ativos. `QT_SIT_TRANCADA`, `QT_SIT_DESVINCULADO`, `QT_SIT_TRANSFERIDO` e `QT_SIT_FALECIDO` representam outras situações. Transferência para outro curso da mesma IES é encerramento no curso de origem, mas não necessariamente saída da educação superior.

No recorte MT não foram encontrados valores negativos, valores ausentes ou valores não numéricos nas colunas `QT_`. Os totais por sexo reconciliaram com ingressantes, matrículas e concluintes em todas as linhas. Isso não dispensa contratos para futuras versões.

Há 2.159, 3.263, 3.679 e 4.279 linhas com matrículas iguais a zero. Divisões por matrícula devem produzir resultado indisponível quando o denominador for zero. Uma taxa igual a zero só é válida quando existe denominador positivo.

4. Indicadores de trajetória

4.1 Estrutura, cobertura e chaves

Cada ZIP contém XLSX, ODS, dicionário DOCX e arquivo de verificação. O cabeçalho técnico do XLSX está na linha 9, com 31 campos. As linhas anteriores contêm títulos e descrições, e há uma linha de nota após os dados. Ler o cabeçalho pelo conjunto esperado de códigos, com a linha 9 como contrato da versão atual.

Coorte	Linhas nacionais válidas	Linhas MT	Cursos MT	Janela observada
2015	281.430	5.150	515	2015 a 2024
2016	263.178	5.157	573	2016 a 2024
2017	247.200	4.864	608	2017 a 2024
2018	230.209	4.361	623	2018 a 2024
2019	206.808	3.876	646	2019 a 2024
2020	174.240	3.105	621	2020 a 2024

A chave `(CO_CURSO, NU_ANO_INGRESSO, NU_ANO_REFERENCIA)` foi única em todos os arquivos nacionais. No recorte MT existem 784 códigos de curso distintos entre todas as coortes e 26.513 observações. Cada curso e coorte tem todos os anos esperados, sem lacunas. A quantidade de ingressantes é constante dentro de cada curso e coorte.

Todas as 26.513 observações filtradas por `CO_UF = 51` são presenciais. No arquivo nacional da coorte 2020, os 26.230 registros EAD têm UF vazia. Portanto, a trajetória EAD não é territorializada por esse filtro. Não atribuir uma trajetória nacional EAD aos estudantes de polos em MT sem uma regra adicional e sem declarar a diferença de população.

4.2 Três tempos diferentes

Preservar `ano_ingresso`, `ano_referencia` e `ano_perfil_curso`. O dicionário informa que instituição, categoria administrativa, modalidade e localização correspondem ao último ano de análise, que nesta edição é 2024.

Uma linha com referência 2015 não fornece necessariamente a categoria ou instituição observada em 2015. Usar esses atributos para segmentar a trajetória é possível, mas o dashboard deve descrever a classificação pela edição de 2024. Uma dimensão histórica construída com o Censo 2021 a 2024 cobre somente esse intervalo, não recupera 2015 a 2020.

O prazo máximo previsto de acompanhamento também não é um ano já observado. Existem coortes recentes cujo prazo se estende além de 2024. A comparação precisa usar `ano_relativo = ano_referencia - ano_ingresso + 1`. O horizonte comum a todas as coortes disponíveis é o quinto ano, observado de 2019 a 2024, conforme a coorte.

4.3 Falecimentos e reconstrução das taxas

Foi testada a correspondência das cinco taxas com as contagens em todas as observações MT. Definindo:

```
N = ingressantes da coorte no curso
F(t) = soma de QT_FALECIDO até o ano t
C(t) = soma de QT_CONCLUINTE até o ano t
D(t) = soma de QT_DESISTENCIA até o ano t
E(t) = N - F(t)

TAP(t)  = 100 × QT_PERMANENCIA(t) / E(t)
TCA(t)  = 100 × C(t) / E(t)
TDA(t)  = 100 × D(t) / E(t)
TCAN(t) = 100 × QT_CONCLUINTE(t) / E(t)
TADA(t) = 100 × QT_DESISTENCIA(t) / E(t)
```

Essa reconstrução reconciliou todos os valores MT dentro de tolerância de 0,00001 ponto percentual. Usar apenas `N` como denominador produziu divergências de até 5 pontos percentuais em registros de TDA. A identidade de contagens também reconciliou: permanência mais conclusões acumuladas, desistências acumuladas e falecimentos acumulados é igual aos ingressantes.

Essa é uma validação empírica dos arquivos examinados. O ETL deve preservar as taxas publicadas e suas contagens, registrar a fórmula e repetir a reconciliação em cada nova versão. Não arredondar antes da agregação.

O campo técnico anual é `TADA`, embora parte das descrições utilize a sigla TDAN. Mapear pelo significado e pelo campo técnico. `QT_CONCLUINTE` e `QT_DESISTENCIA` são anuais; os acumulados precisam ser construídos em janela ordenada por curso e coorte. Não aplicar janela sobre uma tabela que já foi multiplicada por um relacionamento.

Para uma taxa do conjunto de cursos, somar os numeradores e os denominadores efetivos na mesma coorte e referência. A média simples dos percentuais dá o mesmo peso a cursos pequenos e grandes. Na coorte 2015 presencial em MT, em 2024, a média simples da TDA foi 57,74%, enquanto a taxa pelas contagens foi 59,90%. O controle reúne 515 cursos, 41.918 ingressantes e denominador efetivo de 41.889.

Para localizar o ano de maior perda, usar o número anual de desistências ou a taxa anual publicada, conforme a definição escolhida. A diferença entre duas TDAs acumuladas pode diferir da taxa anual quando muda o denominador por falecimentos. Declarar se o gráfico mostra pessoas por ano, pontos percentuais da coorte ou proporção condicional entre quem ainda permanecia. São medidas diferentes.

5. CPC, Enade, IDD e IGC

5.1 Quantidade de registros MT nas abas principais

Fonte	2021	2022	2023
CPC	155	165	238
Enade	155	165	238
IDD	155	165	238
IGC	45	45	51

Em 2025, a planilha de licenciaturas tem 4.948 registros nacionais válidos e 97 em MT. A de Medicina tem 351 nacionais e sete em MT. As contagens excluem rodapés e notas. A existência de um registro não garante conceito calculado.

As planilhas mudam nome de aba, ordem, espaços iniciais, notas em asteriscos e sobrescritos. O Enade 2021 começa com uma aba de apoio, não com a base principal. O IGC inclui abas auxiliares de cursos e pós-graduação, e o IGC 2023 inclui abas semelhantes ou repetidas. Escolher a aba por cabeçalhos e conteúdo esperados. Não concatenar todas as abas.

CPC, Enade e IDD têm grão curso e edição. A chave `(ano_edicao, CO_CURSO)` não apresentou duplicações nas abas nacionais examinadas. O IGC tem grão instituição e edição. Seu valor pode ser associado aos cursos como contexto institucional, mas não deve ser contado novamente para cada curso ao calcular médias institucionais.

5.2 Ausência de conceito e divergência entre fontes

`SC`, vazio, espaço e célula ausente aparecem em medidas ou faixas. Converter um conceito válido de 1 a 5 para inteiro. Manter um status separado para sem conceito, não avaliado e dado ausente. Uma nota desconhecida nunca deve se tornar zero.

Foi encontrada uma divergência concreta na planilha CPC 2022: em 957 cursos nacionais, o campo de Conceito Enade contínuo embutido contém zero, enquanto a planilha própria do Enade tem conceito contínuo ausente e faixa `SC`. Esses zeros não devem entrar em uma média de Enade. Usar a publicação própria como fonte principal do indicador e registrar a divergência entre publicações. Não presumir que todo zero encontrado em qualquer indicador seja ausente.

Há métricas repetidas entre CPC e os arquivos próprios do Enade e IDD. Definir uma fonte principal por indicador e usar os campos repetidos para reconciliação. Não carregar a mesma nota como se fossem duas avaliações independentes.

5.3 Enade 2025 utiliza frações no arquivo

Os percentuais de proficiência de 2025 são armazenados como frações, por exemplo 0,727 corresponde a 72,7%. As taxas de trajetória estão na escala 0 a 100. O contrato precisa declarar a escala de cada medida. Preservar a escala publicada no fato com sufixos explícitos, como `tap_pct` e `proficiencia_razao`. Na apresentação, padronizar a exibição e declarar a unidade. Não converter novamente uma fração que já foi normalizada.

Na planilha de licenciaturas, 91 dos 97 cursos MT têm proficiência numérica. Dos 75 cursos que cruzam com alguma trajetória, 70 têm proficiência numérica. A diferença entre a fração publicada e a razão das contagens foi de no máximo 0,0005, compatível com arredondamento a três casas decimais.

Preservar inscritos, participantes e participantes acima do padrão. Para agregar proficiência, calcular a soma dos participantes acima do padrão dividida pela soma dos participantes dos cursos elegíveis. Não incluir participantes de cursos sem cálculo válido apenas no denominador.

O percentual de proficiência refere-se aos concluintes participantes da avaliação de 2025. As coortes de trajetória são de 2015 a 2020, acompanhadas até 2024. Não multiplicar a TCA de uma coorte antiga pela proficiência de 2025 para afirmar quantos de seus ingressantes se tornaram proficientes. O relacionamento é entre resultados do mesmo curso em populações e períodos distintos.

6. IBGE

6.1 Estrutura longa, classificações e cobertura

Tabela	Linhas MT e UF	Primeiro e último período	Municípios no arquivo	Sinais de zero -	Indisponíveis . . .
9514	342.504	2022 a 2022	141	30.364	0
10056	81.792	2022 a 2022	141	32.045	0
10059	511.200	2022 a 2022	141	399.998	0
10061	485.640	2022 a 2022	141	173.378	0
10296	61.344	2022 a 2022	141	22.438	0
5938	143.704	2002 a 2023	141	426	11.636
6579	3.146	2001 a 2026	142	0	26

A indicação de primeiro e último período não implica série contínua. As cinco tabelas demográficas têm somente 2022. O PIB tem 22 períodos, de 2002 a 2023. A população estimada tem 22 períodos: 2001 a 2006, 2008, 2009, 2011 a 2021 e 2024 a 2026. Não há estimativas de 2022 e 2023 nessa tabela recebida.

Cada observação é identificada por tabela, variável, nível geográfico, localidade, período e combinação completa das categorias de classificação. Nenhuma das 1.629.330 linhas apresentou duplicação dessa chave. N3 identifica a UF e N6 identifica municípios. Todos os arquivos também contêm a linha de MT. Não somar a UF aos municípios.

As classificações contêm totais, subtotais e categorias detalhadas sobrepostas. Não somar todas as linhas para produzir população. Selecionar explicitamente sexo total, raça total, faixa etária e outras dimensões exigidas pela pergunta. Uma junção por município sem filtrar as categorias pode multiplicar cada curso por milhares de observações.

Manter uma tabela de metadados para variáveis, unidades, classificações e categorias. O nome de uma categoria não é uma chave estável suficiente. O mesmo código de variável em agregados diferentes pode representar outro contexto. Usar sempre tabela e variável conjuntamente.

6.2 Marcadores e unidades

Foram encontrados 658.649 valores `-` e 11.662 valores `...`. A convenção do IBGE distingue zero absoluto de informação indisponível. O adaptador deve converter `-` em zero numérico mantendo `situacao_valor = zero_absoluto`, e converter `...` em NULL mantendo `situacao_valor = indisponivel`.

Também prever `..` e `X` como sinais documentados de não aplicação e supressão, mesmo que não tenham aparecido neste recorte. Um símbolo desconhecido deve ser registrado para análise, sem conversão silenciosa. Preservar `valor_original` em todos os casos.

As variáveis monetárias da tabela 5938 estão em mil reais. Para chegar a reais, multiplicar por 1.000 e manter o valor e a unidade originais. Participações estão em porcentagem. PIB a preços correntes não mede crescimento real sem deflator, e deflator não está neste pacote.

6.3 Denominador de jovens de 18 a 24 anos

Para o bônus B1, a tabela 9514 permite um denominador municipal exato do Censo 2022:

Seleção	Código
Variável população residente	93
Sexo total, classificação 2	6794
Forma de declaração total, classificação 286	113635
Idades simples de 18 a 24, classificação 287	6575, 6576, 6577, 6578, 6579, 6580, 6581
Nível municipal	N6
Período	2022

A soma dessas sete idades por município reconciliou exatamente com o total de MT: 397.671 jovens. Somar grupos etários junto com idades simples duplicaria o denominador. A estimativa de população total da tabela 6579 não substitui a população de 18 a 24 anos.

O corte recomendado para B1 é vagas presenciais novas de graduação do Censo 2022, dividido pelos jovens de 2022. Se optar por vagas totais, identificar isso no título e não misturar os dois numeradores. Uma comparação de vagas de 2024 com jovens de 2022 deve exibir os dois anos e ser tratada como uma aproximação com denominador fixo.

Usar os 141 municípios de 2022 como universo e relacionar a oferta por LEFT JOIN. Existem 42 municípios com registros presenciais de graduação em 2022 e 106 sem vagas novas presenciais naquele arquivo, incluindo municípios com registros sem vagas novas. Essa diferença mostra por que ausência de registros e ausência de vagas precisam ter critérios explícitos. O total de vagas novas presenciais usado no controle foi 65.177. O resultado mede oferta no município, não acesso individual nem deslocamento dos jovens.

6.4 Geografia histórica

A tabela de estimativas contém 142 municípios, enquanto o Censo 2022 e o PIB contêm 141. O código adicional é 5101837, Boa Esperança do Norte. Nas estimativas recebidas, seus valores são indisponíveis até 2024 e informados em 2025 e 2026. Também há ausências nos anos iniciais de Ipiranga do Norte e Itanhangá.

Não montar um painel histórico usando somente a lista municipal atual e preenchendo tudo o que não encontra com zero. Preservar a versão territorial e a cobertura por período. Uma nova geografia exige correspondência territorial oficial ou agregação para uma área comparável. Não redistribuir populações antigas entre municípios por estimativa própria.

7. Relações possíveis e perdas de cobertura

Relacionamento medido	Resultado	Consequência
CPC 2021 MT com qualquer trajetória fornecida	140 de 155 cursos; 135 com CPC numérico	Publicar tamanho e perfil da amostra válida
CPC 2022 MT com qualquer trajetória fornecida	154 de 165; 137 com CPC numérico	Tratar ausência de conceito e ausência de trajetória separadamente
CPC 2023 MT com qualquer trajetória fornecida	234 de 238; 225 com CPC numérico	A boa cobertura de uma edição não garante cobertura de todas as coortes
Licenciaturas 2025 MT com trajetória	75 de 97; 70 com proficiência numérica	Explicitar cursos recentes e EAD fora do cruzamento
Medicina 2025 MT com trajetória	Sete de sete	Preservar edição e população da avaliação
Cursos da trajetória com Censo MT 2024	646 de 784 códigos	138 sem registro correspondente naquele recorte anual

As 97 licenciaturas MT incluem 84 presenciais e 13 EAD. As trajetórias MT fornecidas cobrem apenas presenciais. Os nove cursos presenciais restantes também não têm trajetória nessas coortes. Ausência pode decorrer da janela de ingresso, de cursos novos ou de outras diferenças de cobertura; não representa evasão zero.

O código de curso 96004 aparece com IES 2330 no CPC 2022 e IES 1941 na trajetória da edição 2024. Isso confirma que uma junção rígida por curso e instituição de anos diferentes pode perder um curso identificável. Relacionar pelo código global do curso, conferir a instituição e registrar divergências históricas. Uma correspondência baseada apenas em nomes não deve substituir essa regra.

Para o Censo EAD, também manter avaliações de instituições fora de MT: em 2022, 755 cursos da publicação nacional do CPC têm código presente no recorte do Censo MT, e 590 dessas avaliações têm UF diferente de MT. Descartar previamente toda a qualidade fora de MT perde contexto de cursos que possuem vínculos geográficos em MT. Isso não transforma a nota nacional do curso em uma nota específica de seu polo municipal.

8. Modelo PostgreSQL proposto

Camada	Conteúdo	Regra principal
Arquivos originais	ZIP, XLSX, ODS, JSON, dicionários e notas	Conteúdo imutável, hash e origem registrados
`ops`	Dataset, execução, validação, quarentena e publicação	Uma execução identificável e uma seleção explícita de versões
`staging`	Registros extraídos no leiaute da fonte	Rastreabilidade até membro, aba e linha; sem regras de dashboard
`core`	Fatos tipados e dimensões com grão definido	Contagens, códigos, datas, unidades e status preservados
`mart`	Produtos por pergunta, já agregados	Relações de cardinalidade controlada e denominadores explícitos

Tabelas de fatos:

Tabela	Grão	Medidas principais
`core.fato_trajetoria`	Versão, curso, coorte e ano de referência	Contagens anuais, permanência e cinco taxas publicadas
`core.fato_censo_localidade`	Versão, ano, dimensão, curso e localidade	Matrículas, ingresso, conclusão, situações, vagas e financiamento
`core.fato_qualidade_curso`	Versão, indicador, edição e curso	Conceito contínuo, faixa, proficiência, participantes e status
`core.fato_igc`	Versão, edição e instituição	IGC contínuo e faixa
`core.fato_ibge`	Versão, tabela, variável, geografia, período e categorias	Valor, unidade, status e valor original

Dimensões úteis: instituição por ano, modalidade, grau, rede, área CINE, localidade por versão territorial e metadados das classificações IBGE. A instituição histórica continua sendo atributo do fato observado. Não substituir todas as instituições de um curso pelo cadastro mais recente.

No primeiro modelo, categorias IBGE podem ser armazenadas em JSONB canônico, mantendo IDs de classificação e de categoria. Em evolução, criar uma dimensão de combinação de categorias e uma tabela de seus componentes para reduzir repetição e simplificar filtros. Evitar um modelo genérico de atributo e valor para os fatos do Censo e da trajetória: essas medidas são conhecidas e precisam de regras próprias.

Contagens devem usar BIGINT. Códigos territoriais e CINE devem usar texto. Conceitos e taxas devem usar NUMERIC, sem arredondamento prematuro. Datas de coleta e processamento devem usar TIMESTAMPTZ. Uma célula sem conceito fica com valor NULL e motivo explícito.

O SQL anexo mostra a estrutura central, chaves e consultas de referência. Não é uma migração aplicada nem um carregador completo. Dimensões adicionais, permissões e publicação precisam ser implementadas na etapa de construção.

9. Três caminhos de execução

Primeiro, decidir onde cada transformação deve acontecer:

Estratégia	Transformação principal	Quando faz sentido	Ponto de atenção
ETL concentrado em Python	Tipagem, relações e agregações antes de carregar o banco	Exploração local e entrega inicial por arquivos, com equipe que domina Python	Regras podem ficar dispersas em scripts; manter contratos e reconciliar os produtos
ELT concentrado no PostgreSQL	Adaptadores abrem os formatos; staging preserva campos e SQL faz tipagem, filtros e relações	Equipe que trabalha principalmente em SQL e precisa revisar transformações no banco	XLSX e JSON ainda precisam de adaptadores; o banco guarda mais registros intermediários
Híbrido	Python resolve formato e seleção de escopo; SQL resolve relações, janelas e marts	Recomendado para este conjunto	Declarar a responsabilidade de cada regra para evitar duas implementações divergentes

Em qualquer estratégia, preservar os originais completos e as versões de transformação. Não é necessário guardar o conteúdo binário dos ZIPs dentro de tabelas PostgreSQL. A camada original pode continuar em arquivos com referência e hash registrados no banco.

Depois, escolher a organização e a orquestração:

Caminho	Como funciona	Vantagens	Custo e uso recomendado
A. Python e PostgreSQL	Adaptadores por fonte, COPY para staging, SQL para core e mart	Poucas peças, regras visíveis, fácil reprodução	Recomendado para o hackathon e primeira entrega
B. Python, PostgreSQL e dbt	Mesma extração, transformações e relações organizadas em modelos SQL	Dependências, testes e documentação dos modelos	Útil quando várias pessoas mantêm muitos modelos SQL
C. Airflow com A ou B	Orquestra coleta, extração, validação, publicação e reprocessamento	Histórico operacional, dependências e recuperação de tarefas	Evolução para atualização recorrente; requer operação dos componentes

dbt não substitui o adaptador de ZIP/XLSX ou a coleta da API. Airflow organiza a execução dos trabalhos; a lógica de análise continua nos adaptadores e no SQL. Preparar funções e comandos que aceitem versão e ano facilita migrar de A para B ou C sem reescrever a metodologia.

Ferramentas visuais de integração também podem extrair, tipar e carregar. Neste conjunto, será necessário configurar conscientemente a aba principal, cabeçalhos, tipos, sinais do IBGE e categorias geográficas. Sua vantagem depende de a equipe já dominar uma ferramenta. A avaliação central é a reprodutibilidade das regras, não o desenho visual do fluxo.

Não há necessidade demonstrada de Spark, Kafka, CDC ou streaming para estes arquivos anuais e este recorte. Essa é uma decisão de arquitetura a partir do volume medido, não um benchmark de desempenho do PostgreSQL.

10. Fluxo detalhado do caminho recomendado

1. Registrar fontes, competência, URL, versão publicada, SHA-256, tamanho, instante de coleta e dicionário associado. Reutilizar os originais já baixados.
2. Validar a integridade do arquivo e descobrir os membros pela família. Os caminhos internos antigos têm caracteres corrompidos na nomenclatura; não depender da grafia exata da pasta.
3. Confirmar cabeçalhos, abas e presença das colunas obrigatórias. Mudança incompatível deve parar aquela fonte antes de publicar dados incorretos.
4. Extrair os CSVs do Censo em blocos. Filtrar os fatos geográficos de MT e manter os cadastros nacionais necessários. Preservar nacionalmente os originais e o contexto EAD sem localização.

5. Ler a trajetória em fluxo, selecionar MT e manter coorte e referência. Selecionar somente as abas principais de qualidade, preservando dados nacionais relevantes aos cursos EAD e aos históricos de IES.
6. Interpretar o IBGE com seus metadados. Separar valor numérico de sinal, unidade e categoria. Produzir seleções analíticas específicas, mantendo o arquivo completo como referência.
7. Carregar tabelas de staging por COPY. Declarar as colunas e usar conteúdo preparado em UTF-8. Em um banco remoto, `COPY FROM STDIN` transmite pelo cliente; `COPY` com caminho de arquivo usa o sistema de arquivos do servidor.
8. Aplicar validações de estrutura, tipo, unicidade, unidade, população e integridade referencial. Registrar registros rejeitados e motivos. Ausência oficial de conceito não é falha de parsing.
9. Transformar para core, construir acumulados antes dos cruzamentos e materializar as agregações por pergunta.
10. Validar novamente contagens e totais após cada relação. Publicar uma seleção consistente de versões somente após os controles necessários.
11. Exportar CSVs de apresentação e os dados do dashboard. Registrar fórmula, coorte, ano, cobertura e supressões no contrato de cada produto.

No IBGE, a coleta futura deve partir de metadados, períodos e localidades, com lotes pequenos e retomada dos lotes concluídos. Durante o download, requisições maiores falharam com HTTP 500 e a divisão em lotes resolveu o problema. Usar essa observação para um ponto inicial de tamanho de lote, com redução adaptativa e retentativas limitadas. Não tratá-la como um limite oficial de API. Decodificar a compressão de resposta antes de interpretar JSON.

O ambiente de coleta apresentou dificuldades de certificados em alguns downloads INEP. Um processo recorrente deve corrigir certificados e cadeia de confiança. Não incorporar a desativação de verificação TLS como solução padrão. Conservar a URL solicitada e a URL efetivamente usada no catálogo.

11. Reprocessamento, revisões e publicação

As fontes podem revisar um arquivo sem trocar seu nome ou URL. Uma carga incremental baseada apenas no maior ano falha nesse cenário. A nota informativa 02 do Censo 2023 documenta a correção de vagas e inscritos do IFMT, código 3164, após a divulgação inicial. A página do INEP também identifica atualizações posteriores nas planilhas de 2025.

A unidade de reprocessamento deve ser a versão do arquivo ou o lote da API. Usar a combinação de hash da fonte, versão do contrato e versão do código para reconhecer uma carga já concluída. Mesmo arquivo com novo contrato pode exigir nova extração.

Guardar versões antigas. Criar uma publicação que referencia exatamente uma versão por família e competência, juntamente com a versão dos marts. A nova execução não deve

adicionar uma segunda cópia aos mesmos indicadores. A publicação muda apenas quando o conjunto está pronto.

Uma arquitetura simples pode usar transação para gravar core e atualizar o conjunto selecionado. Em uma evolução com materializações, preparar uma nova versão dos produtos e alterar a referência da publicação em transação. Se ocorrer falha, conservar a publicação anterior. A atomicidade da publicação não elimina a necessidade de transações e validações em cada carga.

12. Produtos para as perguntas do desafio

Pergunta	Produto e regras	Limite relevante
P1	Curva da coorte 2015 presencial, com contagens anuais, acumuladas e denominador efetivo	Atributos dos cursos são os da edição 2024
P2	Comparação por curso e área no mesmo ano relativo; quinto ano para todas as coortes	Não comparar taxas finais com horizontes de cinco e dez anos
P3	Censo de graduação por rede e modalidade em 2021 a 2024; situações e matrículas com definição operacional explícita	Esses CSVs não fornecem evasão individual longitudinal
P4	Uma observação por curso e coorte em horizonte escolhido, com um CPC selecionado e amostra válida registrada	Associação agregada, ciclos de avaliação e composição dos cursos
P5	Trajetória de licenciaturas e proficiência de concluintes em 2025, com cobertura do relacionamento	Coortes antigas e participantes de 2025 são populações diferentes
B1	Vagas presenciais novas em 2022 por 100 jovens de 18 a 24 em 2022, incluindo municípios sem oferta	Oferta local não mede deslocamento ou acesso individual
B2	FIES, ProUni integral e parcial, separadamente, por matrículas privadas e ano	Contagens de programas podem sobrepor participantes

12.1 Como tratar a evasão anual em P3

Se for necessário produzir uma proporção a partir das situações do Censo, uma definição operacional possível é:

```
encerramentos_no_curso = desvinculados + transferidos
vinculos_declarados = matriculas + trancados + desvinculados + transferidos +
    falecidos
proporcao_encerramentos = encerramentos_no_curso / vinculos_declarados
```

Essa proporção descreve situações declaradas no arquivo anual por vínculo ao curso. Não é apresentada aqui como uma taxa oficial de desistência do INEP nem como probabilidade individual de evasão. Ela inclui transferências internas e pode contabilizar a mesma pessoa em cursos diferentes. Se o objetivo excluir transferências, disponibilizar também a medida apenas de desvinculados e identificar o numerador.

Outro caminho é usar as taxas anuais da trajetória, preservando o denominador da coorte. Nesse caso, em MT a análise estará limitada ao presencial e às coortes 2015 a 2020. Não denominar o resultado de todos os estudantes matriculados no estado. Um estimador baseado em matrículas de anos consecutivos requer hipóteses adicionais sobre ingresso, conclusão e transferências e não deve ser a primeira definição do painel.

12.2 Como tratar qualidade e financiamento

No P4, selecionar um CPC por curso com regra temporal explícita. Para estudo descritivo da edição disponível, pode-se usar o CPC do ciclo 2021 a 2023 e a desistência no horizonte escolhido, registrando a diferença entre anos. Para uma alegação de efeito anterior sobre a evasão, seria necessária qualidade observada antes ou no início do acompanhamento; este pacote não fornece essa cobertura histórica completa.

Comparar dentro de áreas, rede e porte ajuda a avaliar composição. Cursos sem CPC não recebem nota zero. Evitar rankings de cursos pequenos e correlações que tratem cada linha anual do mesmo curso como uma observação independente. A amostra com qualidade pode diferir dos cursos sem avaliação.

No B2, cada contagem individual de FIES e ProUni foi menor ou igual às matrículas em todas as linhas MT. Entretanto, uma linha de 2021 apresentou soma dos três programas superior às matrículas. Isso evidencia sobreposição possível ou diferença de declaração que impede considerar essa soma uma quantidade de beneficiários únicos. Manter proporções separadas e usar a contagem de financiamento total apenas para o conceito mais amplo que ela realmente representa.

13. Controles de qualidade e decisões em caso de falha

Controle	Resultado nesta análise	Tratamento em nova carga
Cabeçalho e aba principal	Diferenças identificadas e mapeadas	Parar a fonte se campo essencial desaparecer ou perder significado
Unicidade no grão da fonte	Sem duplicações nas chaves completas testadas	Investigar conflito; não aplicar DISTINCT como correção automática
Código municipal válido no recorte MT	Sem ausências nos fatos Censo MT	Separar ausência oficial, geografia não aplicável e erro
Curso e IES no cadastro nacional anual	Todos os códigos Censo MT encontrados	Registrar órfãos e verificar mudança institucional
Contagens Censo MT	Não negativas e numéricas	Rejeitar conversão inválida com linha e campo de origem
Sexo e total no Censo MT	Todas as linhas reconciliaram	Impedir publicação da medida inconsistente
Ingressantes constantes e anos consecutivos	Todas as trajetórias MT reconciliaram	Não construir acumulados sobre séries incompletas sem sinalização
Saldo da coorte e cinco taxas	Reconciliação integral em MT	Preservar publicado, investigar fórmula ou versão
Escalas e unidades	Trajetória 0 a 100; proficiência 0 a 1; PIB em mil reais	Aplicar conversão explícita e rastreável
Chave completa IBGE	Sem duplicações	Validar categorias, variáveis e níveis antes de juntar
Denominador B1	Soma municipal e MT iguais a 397.671	Parar a medida se geografia, período ou faixa etária divergir
Ausência de conceito e sinais oficiais	SC, vazio, zero absoluto e indisponível distinguidos	Preservar status, sem fillna(0) genérico
Cardinalidade após relações	Cobertura medida e perdas identificadas	Contagem e soma de controle antes e depois da relação

Erro de parsing, chave conflitante e ausência oficial são estados distintos. A quarentena deve registrar o primeiro grupo; o segundo precisa investigação; o terceiro continua disponível com status informativo. A publicação deve bloquear somente os produtos

afetados ou o conjunto inteiro quando a falha comprometer sua consistência, conforme as dependências definidas.

Os dados de apresentação precisam respeitar a regra do evento de não expor células com menos de dez alunos. Aplicar a regra aos numeradores, denominadores e detalhamentos relevantes, inclusive exportações. Impedir recuperação indireta por subtotais quando necessária supressão complementar. Preservar internamente os valores originais para reconciliação. As evidências anexas foram reduzidas a perfis e diagnósticos de estrutura, sem disponibilizar os recortes intermediários de estudantes por curso e localidade.

14. Desempenho e operação

O recorte anual do Censo e a trajetória de MT são pequenos para um banco relacional. O IBGE completo tem cerca de 1,6 milhão de linhas, mas os produtos de apresentação podem ser muito menores com seleções explícitas de categorias. Não carregar o dashboard diretamente sobre todos os cruzamentos brutos.

Usar COPY para a carga, transações para lotes relacionados e ANALYZE depois de cargas relevantes. Começar com índices nas chaves e filtros realmente usados: curso, ano, coorte, edição, município e seleção de versão. Para o IBGE, um índice por tabela, variável, nível, localidade e período atende às seleções comuns; a combinação de categorias continua parte da chave de unicidade.

Adicionar materializações quando uma consulta medida for repetidamente lenta. `REFRESH MATERIALIZED VIEW CONCURRENTLY` exige materialização já populada e índice UNIQUE adequado; não é uma garantia geral de publicação simultânea de vários produtos. Não aplicar particionamento por mês em dados anuais. Considerar partições por ano ou tabela somente após medir benefício ou quando facilitar substituição de versões e manutenção em escala maior.

O plano operacional deve medir tempo por etapa, pico de memória, linhas lidas, selecionadas, rejeitadas e publicadas, tamanho das tabelas e latência das consultas do painel. Os tempos de perfilagem deste ambiente não foram utilizados como SLA nem como benchmark de um banco que não foi executado.

15. Ordem prática de implementação

1. Implementar os contratos de trajetória e Censo, a identificação de versões e as chaves corretas. Validar a reconstrução da coorte e a dimensão do EAD.
2. Entregar P1, P2 e o produto de matrículas e situações de P3 com definição operacional visível.
3. Implementar os adaptadores de qualidade, preservar SC e a escala de proficiência, medir a cobertura e entregar P4 e P5.
4. Entregar B1 com numerador e denominador de 2022. É um caminho adicional bem definido e com reconciliação territorial possível no pacote.

5. Entregar B2 com programas separados e associações descritivas, se houver tempo.
6. Validar relações e exportações, aplicar supressões, preparar reprodução e demonstrar nova execução sem duplicar dados.
7. Após a entrega, avaliar dbt, Airflow e publicação recorrente com base no custo de manutenção observado.

Os critérios de conclusão são: indicadores reproduzíveis, contratos e fórmulas documentados, seleção explícita de versões, nenhuma multiplicação indevida de registros, cobertura visível, reprodução a partir dos arquivos originais e uma saída utilizável pelo dashboard. As etapas técnicas de criação de banco e carregamento continuam propostas, não executadas nesta análise.

16. Conteúdo dos anexos

- Perfis JSON com contagens, leiautes, chaves, sinais e verificações realizadas.
- Contratos JSON propostos com campos de origem, chaves, escalas e regras por família.
- Modelo PostgreSQL e consultas de referência para análise e validação.
- Script de perfilagem reproduzível, de leitura, com parâmetros de diretório e família.
- Catálogo de origem e hashes dos arquivos recebidos.

Não foram incluídos novos downloads completos, duplicatas das bases nem os recortes intermediários. Os três ZIPs de dados já fornecidos permanecem como fontes da análise.

17. Fontes e documentação

Evidência principal: arquivos INEP e IBGE da lista fornecida, seus dicionários e notas internas, metadados da API e apresentação de abertura do evento. Os caminhos relativos exatos e hashes constam no catálogo anexo. A nota de correção do IFMT é `Nota Informativa 02.pdf`, no ZIP do Censo 2023, datada de 13/10/2025. A geografia do EAD e a proteção do código CINE constam da nota informativa incluída nos ZIPs do Censo.

Documentação oficial consultada em 10/10/2026:

1. INEP, Indicadores de Trajetória.
   https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/indicadores-educacionais/indicadores-de-trajetoria-da-educacao-superior
2. INEP, resultados de qualidade 2025 e atualizações dos arquivos.
   https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/indicadores-educacionais/indicadores-de-qualidade-da-educacao-superior/2025
3. IBGE, API de agregados.
   https://servicodados.ibge.gov.br/api/docs/agregados?versao=3

4. IBGE, convenção de símbolos, explicação da produção agropecuária. A convenção dos símbolos também deve ser confrontada com as notas do agregado em cada nova fonte.
   https://www.ibge.gov.br/explica/producao-agropecuaria/acai-cultivo/br
5. PostgreSQL, COPY.
   https://www.postgresql.org/docs/current/sql-copy.html
6. PostgreSQL, carga e ANALYZE.
   https://www.postgresql.org/docs/current/populate.html
7. PostgreSQL, particionamento.
   https://www.postgresql.org/docs/current/ddl-partitioning.html
8. PostgreSQL, atualização de materializações.
   https://www.postgresql.org/docs/current/sql-refreshmaterializedview.html
9. dbt, modelos SQL.
   https://docs.getdbt.com/docs/build/sql-models
10. Apache Airflow, arquitetura e fluxos.
    https://airflow.apache.org/docs/apache-airflow/stable/core-concepts/overview.html