Roadmap da Rota do Diploma com PostgreSQL

Plano de execução para o DataHack Univag 2026

Este roadmap orienta a equipe a entregar uma solução que responda à pergunta central do desafio: de cada 100 ingressantes em uma graduação em Mato Grosso, quantos chegam ao diploma e em quais cursos a trajetória se interrompe. A solução deve responder às cinco perguntas obrigatórias, incluir pelo menos um bônus e apresentar resultados verificáveis em um dashboard acessível à banca.

A arquitetura proposta usa PostgreSQL para armazenar, transformar e validar os dados. Python realiza os downloads e a ingestão. Streamlit com Plotly apresenta as tabelas analíticas exportadas. O produto final inclui o dashboard, código reproduzível, documentação das métricas, histórico de uso de IA e um PDF de contingência.

O calendário de referência é sábado, 10 de outubro de 2026, no horário local do evento. Este plano trabalha com entregas às 10h45, 14h15 e 17h. A apresentação contém também horários de 11h e 15h em outros slides. A equipe deve confirmar o cronograma oficial e manter os prazos mais cedo como metas internas. A entrega final às 17h é rígida.

1 Objetivo e critérios de conclusão

O resultado principal será um diagnóstico da trajetória dos cursos de graduação de Mato Grosso. Cada resposta deve trazer indicador, população analisada, período, fonte e uma interpretação que possa orientar uma decisão. As bases são agregadas por curso, turma ou ano. Por isso, as recomendações devem se apoiar em associações observadas, com limitações explícitas.

Entrega	Conteúdo mínimo	Critério de conclusão
Diagnóstico	P1 a P5 e bônus B2	Cada pergunta tem tabela, gráfico, resposta e fonte
Banco	Camadas raw, stg, dw, marts e audit	Ingestão por código e junções sem multiplicar linhas
Qualidade	Testes e relatório de execução	Falhas críticas impedem a publicação
Dashboard	Filtros, indicadores e metodologia	Abre na máquina de apresentação e usa saídas validadas
Reprodutibilidade	Código, manifesto e instruções	Outro integrante executa e reproduz os números
Evidências	Commits, decisões e prompts	Registro atualizado em cada entrega
Contingência	PDF com telas finais	Disponível com o link do pitch antes das 17h

O bônus prioritário será B2, financiamento e permanência, pois utiliza o Censo já necessário para P3. B1, oferta presencial por população jovem, será o segundo bônus se houver tempo. Essa prioridade deve ser revisada na exploração caso os campos de financiamento sejam insuficientes.

O escopo obrigatório termina com um produto analítico e uma recomendação sustentada pelos dados. Modelos preditivos, integração com sistemas internos e uma aplicação administrativa ficam para a evolução posterior ao evento.

2 Ferramentas e arquitetura

Adotar PostgreSQL 18 estável quando disponível, ou a versão suportada já instalada no laboratório. Registrar a versão exata utilizada. Python deve executar um pipeline único, com parâmetros de configuração, logs e código de saída diferente de zero quando houver falha. Fixar as versões das dependências efetivamente testadas em requirements.txt.

Componente	Escolha proposta	Papel na solução
Banco	PostgreSQL local	Cargas, SQL, chaves, transações e auditoria
Ingestão	Python, psycopg, pandas e openpyxl	CSV, XLSX e integração com o banco
Configuração	YAML ou JSON e variáveis de ambiente	URLs, arquivos, períodos e mapeamento de colunas
Dashboard	Streamlit e Plotly	Filtros e visualização das saídas analíticas
Exportação	CSV em UTF-8 e JSON de metadados	Distribuição dos resultados e rastreabilidade
Versionamento	Git e GitHub	Colaboração, commits e documentação
Contingência	PDF com telas e conclusões	Apresentação quando a aplicação não estiver disponível

A escolha do PostgreSQL se justifica pela integração SQL entre bases com níveis de detalhe diferentes, pelas restrições de integridade e pelo controle transacional das cargas. O COPY permite transferência em lote, inclusive pela conexão do cliente. Uma transação permite publicar um conjunto de tabelas de forma conjunta, revertendo a alteração se uma checagem falhar. As referências técnicas estão no final do documento.

Camada	Conteúdo	Regra de utilização
raw	Dados próximos da origem	Manter coluna original, origem, período e execução
stg	Dados tipados e padronizados	Aplicar mapeamentos e recorte territorial documentado
dw	Dimensões e fatos	Manter o nível de detalhe próprio de cada base
marts	Tabelas que respondem às perguntas	Agregar apenas após resolver chaves e denominadores
audit	Cargas, checagens e cobertura	Registrar sucesso, falha, rejeições e taxa de junção

O dashboard final lê outputs. Isso reduz o acoplamento com o banco do laboratório. Um aplicativo Streamlit ainda precisa de um servidor Python para abrir no navegador. Portanto, publicar e testar o aplicativo faz parte da entrega. CSVs em um pendrive, sozinhos, não tornam o aplicativo executável em qualquer computador. Se a publicação não funcionar, preparar uma página HTML autônoma com os gráficos e levar o PDF obrigatório.

3 Fontes e contrato de dados

As equipes devem baixar os arquivos originais pelos links oficiais fornecidos pela organização. Os números apresentados como resultados virão dessas bases, depois das validações. O arquivo fontes_dados.html deve ser a primeira referência operacional para identificar os pacotes esperados pelo evento.

Fonte	Período exigido	Formato informado	Nível de detalhe esperado	Utilização
Trajetória INEP	Coortes 2015 a 2020, até 2024	XLSX, cabeçalho na linha 9	Curso, coorte e ano de referência	P1, P2, P4 e P5
Censo de cursos	2021 a 2024	CSV com ponto e vírgula, latin-1	Curso e ano	P3 e B2
Censo de IES	2021 a 2024	CSV	Instituição e ano	Perfil e integridade das junções
CPC	2021 a 2023	XLSX	Curso e edição da avaliação	P4
Enade Licenciaturas	2025	XLSX	Curso e edição, sujeito ao leiaute	P5
IBGE SIDRA	Ano da tabela selecionada	JSON	Município, idade e outras categorias	B1

IGC e IDD aparecem no mapa conceitual da apresentação, mas a entrega mínima não depende de aprofundá-los. A equipe pode incorporá-los depois de responder P1 a P5 e um bônus.

Para cada arquivo, criar um registro no manifesto com fonte, URL oficial, data de download, nome, tamanho, hash SHA-256, período, planilha selecionada e posição do cabeçalho. Registrar separador, codificação, quantidade de linhas, chave candidata e versão do mapeamento. O manifesto deve permitir identificar exatamente quais bytes produziram o resultado.

O contrato de dados deve relacionar coluna original, nome padronizado, significado, tipo, unidade, regra para nulos e origem da definição. Os nomes de campos neste roadmap são propostas para a camada analítica. O dicionário oficial e os materiais da organização devem confirmar o mapeamento antes da implementação.

Códigos de curso, IES e município ficam como texto. Não converter identificadores para inteiro, não remover zeros por conveniência e não completar códigos inválidos por tentativa. Tratar uma representação numérica de Excel apenas quando houver correspondência inequívoca com o identificador oficial, preservando o valor original na auditoria.

O recorte de Mato Grosso precisa utilizar a variável territorial do curso ou do local de oferta definida no dicionário. A sede de uma IES não identifica necessariamente o município dos alunos ou todos os polos EAD. Quando a territorialidade do EAD representar a sede do curso, o dashboard deve informar esse alcance. B1 usa exclusivamente oferta presencial territorialmente identificável.

4 Distribuição do trabalho da equipe

Os papéis abaixo organizam o trabalho simultâneo dos integrantes. Cada atividade terá um responsável e alguém para revisar o resultado. Se a equipe tiver menos pessoas, combinar papéis e concentrar a revisão nas métricas e na entrega final.

Papel	Responsabilidade principal	Entrega verificável
Coordenação	Cronograma, integração, commits e comunicação	Entregas dentro do prazo e repositório acessível
Engenharia de dados	Ambiente, downloads, carga e modelo	Pipeline executável e banco auditável
Análise	Dicionários, métricas e interpretação	Respostas P1 a P5 e bônus conferidas
Produto e apresentação	Dashboard, fontes e narrativa	Aplicação publicada, PDF e pitch ensaiado

Uma pessoa integra as alterações. Cada integrante trabalha em um conjunto definido de arquivos para evitar conflitos durante os micro-pitches. Os responsáveis por análise e engenharia conferem juntos os denominadores e as junções. O apresentador ensaia com o dashboard real e conhece as limitações do recorte.

5 Preparação e ambiente das 8h às 8h45

Na sexta-feira, decidir a stack e os responsáveis. A apresentação informa que a instalação ocorre no sábado, às 8h. Preparar contas e decisões conforme as regras do evento, sem presumir autorização para antecipar a execução avaliada.

Entre 8h e 8h45, criar ou conferir as contas do GitHub, criar um repositório público e aceitar os convites de colaboração. Garantir que todos tenham acesso. Criar README, .gitignore, pastas e o primeiro commit. Conferir os 10 GB livres solicitados pela organização e testar a conexão com PostgreSQL.

O ambiente estará pronto quando um script conseguir conectar, executar SELECT version(), criar uma tabela de teste e inserir e ler uma linha. Em seguida, testar uma amostra do CSV com separador e codificação corretos e uma planilha de trajetória com header=8, após confirmar que a nona linha contém os nomes das colunas.

Guardar credenciais em arquivo local ignorado pelo Git. Publicar somente .env.example sem valores reais. O dashboard publicado deve ler saídas agregadas, sem precisar da senha do banco do laboratório.

Item	Meta interna	Evidência
Contas e colaboração	8h15	Integrantes com convites aceitos
Banco acessível	8h30	Teste de conexão e versão registrada
Leitura de CSV e XLSX	8h40	Amostras interpretadas corretamente
Estrutura e primeiro commit	8h45	README inicial e pastas criadas

Se a instalação local não terminar até 8h30, a coordenação deve acionar um ambiente PostgreSQL alternativo permitido pela organização. Em um serviço com pouco armazenamento, carregar apenas o recorte analítico necessário e registrar a extração feita em Python. Testar acesso na rede do evento antes de continuar.

6 Fase 1 até 10h45

Objetivo: demonstrar que a equipe conhece as fontes e tem uma estratégia implementável. O download completo e a exploração devem avançar enquanto a pessoa responsável pelo banco termina o ambiente.

Horário	Atividade	Resultado esperado
8h45 a 9h15	Consultar fontes, dicionários e amostras; iniciar downloads	Manifesto e inventário das bases
9h15 a 9h45	Conferir cabeçalhos, tipos, nulos e chaves	Relatório de exploração por fonte
9h45 a 10h15	Definir recorte, denominadores e relações	Contrato de dados e regras de métricas
10h15 a 10h30	Consolidar arquitetura e plano do dashboard	docs/estrategia.md e modelo proposto
10h30 a 10h40	Revisar evidências e preparar micro-pitch	Commit e uma página ou três a quatro slides
Até 10h45	Registrar Entrega 1	Link e conteúdo acessíveis

A exploração deve informar volume, colunas esperadas e encontradas, percentuais de nulos nos campos essenciais, valores das categorias e duplicidades na chave candidata. Conferir que a trajetória permite identificar coorte e ano de referência. Não assumir que todas as edições do Censo possuem o mesmo cabeçalho.

Definir as decisões que evitam erros de análise: tempo relativo da coorte, unidade territorial, regra de ponderação, tratamento de cursos sem conceito, edição do CPC e definição da taxa anual de P3. Qualquer definição não resolvida fica registrada com responsável e prazo, antes da criação do mart correspondente.

A Entrega 1 deve mostrar ambiente acessível, fontes conhecidas, uma evidência real de exploração, arquitetura das camadas e plano para responder às perguntas. O micro-pitch dura três minutos, com dois minutos de perguntas. Usar aproximadamente um minuto para as fontes, um minuto para as decisões de modelagem e um minuto para a execução planejada e os riscos já identificados.

7 Fase 2 até 14h15

Objetivo: ter ingestão implementada, dados tratados e um protótipo que já apresente respostas às cinco perguntas obrigatórias. A equipe deve conseguir repetir a carga sem duplicar os fatos.

Horário	Atividade	Resultado esperado
10h45 a 11h30	Carregar trajetória e Censo; iniciar qualidade	raw com dados e auditoria de linhas
11h30 a 12h15	Tipar, filtrar e validar chaves	stg e fatos do recorte MT
12h15 a 13h	Construir P1, P2 e P3	Primeiros marts e gráficos
13h a 13h40	Construir P4 e P5; medir cobertura	Junções de qualidade e licenciaturas
13h40 a 14h	Integrar as páginas do protótipo	Perguntas identificadas e dados reais
14h a 14h10	Reexecutar uma carga e revisar resultados	Evidência inicial de idempotência
Até 14h15	Registrar Entrega 2	Commit, protótipo e plano de conclusão

Ingerir primeiro a trajetória de 2015 e o Censo 2024 para validar o caminho completo em uma amostra relevante. Em seguida, completar as coortes 2016 a 2020, os anos 2021 a 2023 e todas as edições de qualidade necessárias. O resultado final não pode apresentar uma amostra como se fosse o universo de Mato Grosso.

Usar COPY FROM STDIN para os CSVs, respeitando a codificação do conteúdo enviado e a ordem das colunas. Isso evita depender de um caminho visível pelo servidor PostgreSQL. Para XLSX, ler a planilha e o cabeçalho corretos e transferir registros em lote. Trabalhar com leitura incremental quando uma análise em Python exigir DataFrames grandes. Não realizar INSERT isolado para cada linha do Censo.

No desenho principal, carregar os brutos nacionais uma fonte por vez e executar o recorte analítico no banco. Se o armazenamento exigir filtragem anterior à carga, preservar os arquivos originais, registrar linhas nacionais lidas, linhas selecionadas e filtros aplicados. Descrever essa variante como extração com recorte em Python e transformação no PostgreSQL.

A camada stg padroniza tipos, códigos, categorias e unidades. Nulo permanece nulo quando representar dado ausente, suprimido ou não aplicável. Zero só representa zero confirmado. Percentuais devem ter escala definida por coluna e pelo leiaute. Uma taxa menor que 1 não prova que o arquivo usa escala de 0 a 1. A conversão deve considerar a definição e, quando necessário, a formatação de porcentagem do Excel.

Após as cargas, criar os índices nas chaves utilizadas e atualizar as estatísticas com ANALYZE. Medir o tempo das consultas que alimentam o dashboard antes de qualquer ajuste adicional. Como proposta, buscar carregamento inicial do dashboard em até cinco segundos e filtros em até dois segundos no equipamento testado. Essas metas são da solução, não exigências declaradas pelo evento.

8 Modelo de dados PostgreSQL

Uma linha de trajetória não representa uma linha do Censo nem uma linha do Enade. O modelo mantém fatos separados e utiliza dimensões comuns. Só juntar quando a tabela do lado direito possuir uma linha por chave no recorte usado.

Tabela proposta	Chave ou nível de detalhe	Conteúdo principal
dw.dim_curso	co_curso	Identificador estável e descrição de apoio
dw.dim_ies	co_ies	Identificador da instituição
dw.dim_municipio	co_municipio	Código IBGE, nome e UF
dw.fato_trajetoria	co_curso, ano_coorte, ano_referencia	Ingressantes, bases elegíveis, taxas e contagens
dw.fato_censo_curso	co_curso, ano_censo	Matrículas, ingressantes, vagas, situações e financiamento
dw.fato_censo_ies	co_ies, ano_censo	Perfil anual da instituição
dw.fato_cpc	co_curso, ano_avaliacao	Conceito, faixa e condição de avaliação
dw.fato_enade_licenciatura	Chave oficial da edição por curso	Participação e proficiência de 2025
dw.fato_populacao	Município, ano e recortes demográficos	População jovem usada em B1
audit.execucao	id_execucao	Início, fim, versão do código e situação
audit.arquivo	Fonte, período e hash	Proveniência e quantidade de linhas
audit.checagem	Execução, regra e escopo	Resultado, gravidade e evidência

As chaves acima são candidatas. Se uma edição possuir mais de uma linha por curso por causa do local de oferta ou de outro atributo oficial, ampliar a chave ou agregar conforme o dicionário. Não resolver duplicidades com um DISTINCT arbitrário.

Características que mudam no tempo, como rede, modalidade, nome e município, devem permanecer no fato anual ou numa dimensão com vigência. A dimensão de curso, sozinha, não deve substituir o perfil de 2021 pelo de 2024. Para uma análise histórica sem perfil daquele ano, utilizar o atributo presente na trajetória ou identificar explicitamente que o cruzamento usa um perfil posterior.

Campos padronizados da trajetória: co_curso text, co_ies text, ano_coorte integer, ano_referencia integer, ano_relativo integer, qt_ingressante bigint, denominador_taxas numeric, tda numeric, tca numeric e tap numeric. Se a fonte fornecer contagens acumuladas, preservar n_desistencia_acum, n_conclusao_acum e n_permanencia. Armazenar percentuais de 0 a 100 e guardar a origem do denominador.

Criar restrições de chave, anos coerentes, contagens não negativas e taxas entre 0 e 100. Uma restrição de coluna não verifica todas as regras de negócio. Testes SQL separados conferem soma das taxas, evolução e cobertura das junções. Dados rejeitados devem manter motivo e proveniência em área interna, fora das exportações públicas.

9 Carga idempotente e publicação dos resultados

Adotar substituição completa por origem e período para os arquivos de lote do evento. A equipe lê a fonte, carrega uma tabela temporária ou de trabalho, valida e substitui somente o conjunto correspondente ao arquivo. A transação deve preservar o estado anterior quando a validação não passar.

1. Registrar a execução e identificar fonte, período e hash do arquivo.
2. Carregar dados em área de trabalho exclusiva da execução.
3. Conferir volume, colunas, tipos, chaves e regras críticas.
4. Substituir os registros da mesma origem e período dentro de uma transação.
5. Construir os fatos e marts a partir do conjunto aceito.
6. Validar os marts antes de confirmar a publicação.
7. Confirmar a transação e registrar os resultados na auditoria.
8. Exportar todas as tabelas públicas como um conjunto da mesma execução.

Para o volume e o prazo do evento, reconstruir os fatos analíticos do recorte MT e os marts dentro de uma transação é uma opção simples. Os arquivos grandes podem ser preparados em etapas anteriores. A publicação analítica só ocorre quando o conjunto está consistente. Se a transação for revertida, registrar a falha em uma transação separada para preservar o log.

Um hash permite identificar a mesma entrada e evitar repetição desnecessária da ingestão. Ele não substitui uma transformação nova quando o código, o contrato de dados ou o filtro mudar. ON CONFLICT pode tratar atualização por chave, mas deve haver uma estratégia para remover linhas que desapareceram numa nova versão do arquivo. A substituição por origem e período cobre esse caso.

O teste de idempotência usa as mesmas entradas e configuração em duas execuções. Comparar quantidade de registros, unicidade, somas dos indicadores e hash das exportações ordenadas. Excluir timestamps e identificadores de execução da comparação do conteúdo. Acrescentar um teste de falha antes da publicação: o conjunto anterior deve continuar disponível. Acrescentar uma nova versão de arquivo com uma linha removida para verificar que a linha antiga não permanece no fato.

Exportar para uma pasta temporária, validar todos os arquivos e gerar um manifesto com id_execucao, versão do código, fontes e hashes. Só então tornar esse conjunto disponível ao dashboard. Isso evita misturar arquivos de execuções diferentes.

10 Regras analíticas das perguntas obrigatórias

P1 Quanto da turma fica pelo caminho

Selecionar coorte 2015, modalidade presencial e cursos pertencentes ao recorte territorial definido. Em 2024, apresentar desistência acumulada, conclusão acumulada e permanência. Exibir também a evolução anual e o momento de maior aumento da desistência.

TDA, TCA e TAP descrevem a mesma coorte e somam aproximadamente 100%, com tolerância compatível com o arredondamento da fonte. A desistência é medida em relação ao curso acompanhado. A transferência pode representar saída do curso sem abandono de todo o ensino superior. O texto do dashboard deve respeitar essa unidade de análise.

Para agregar cursos, preferir a soma das contagens correspondentes dividida pela soma das bases elegíveis. Quando as taxas forem os únicos indicadores disponíveis, usar média ponderada pelos seus denominadores. Confirmar se há ajuste por falecimento ou outra exclusão. QT_INGRESSANTE pode servir de peso exato apenas quando corresponder à base das taxas. Caso seja uma aproximação, identificá-la como tal.

Fórmula por grupo: TDA agregada = 100 vezes soma das desistências acumuladas dividida pela soma das bases elegíveis. A mesma lógica vale para TCA e TAP. Com taxas e denominadores, taxa agregada = soma de taxa vezes denominador dividida pela soma dos denominadores.

Não somar QT_INGRESSANTE de todos os anos de acompanhamento como se fossem turmas diferentes. Para a coorte de 2015, a base aparece repetida ao longo da série. Cada ponto anual agrega os cursos uma única vez.

Identificar o maior aumento em pontos percentuais entre anos consecutivos. Isso mede acréscimo na taxa acumulada. Uma probabilidade anual entre alunos ainda em risco exige outro denominador. Quando houver contagens acumuladas e bases consistentes, calcular também novos desistentes. Não preencher automaticamente uma lacuna de ano com zero e não ocultar revisões negativas na série.

Visualização: composição por 100 ingressantes e linha da trajetória. Resposta final: conclusão, desistência e permanência em 2024, acompanhadas do ano de maior aumento e da definição utilizada.

P2 Onde a rota mais se perde

Comparar cursos e áreas pela desistência e pela conclusão no mesmo tempo de acompanhamento. Definir ano_relativo = ano_referencia menos ano_coorte. O ingresso é ano_relativo zero. Assim, ano_relativo quatro representa o quinto ano de observação.

Usar o quinto ano de observação como referência comum inicial para as coortes 2015 a 2020, pois todas podem alcançá-lo até 2024. Confirmar a disponibilidade real de cada série. Também é possível mostrar rankings da coorte 2015 em 2024, sempre identificando esse recorte.

Uma comparação entre 2015 em 2024 e 2020 em 2024 mistura tempos diferentes. Para avaliar mudança entre turmas, manter igual o tempo relativo e, quando possível, área, modalidade e duração esperada do curso. Cursos sem a observação necessária ficam marcados como sem cobertura para aquela comparação.

Exibir rankings de maior e menor desistência com bases elegíveis e número de cursos no agregado. Evitar concluir que a média de uma área representa todos os seus cursos. Atribuir prioridade combinando tamanho do problema e taxa, depois da proteção das células pequenas.

Visualização: barras ordenadas por área ou curso e comparação das coortes no mesmo tempo relativo. Resposta final: onde a interrupção é maior e onde o desempenho é melhor, com o tamanho das bases.

P3 Pública e privada presencial e EAD

Usar Censo 2021 a 2024 e classificar as categorias administrativas em pública e privada conforme o dicionário de cada edição. Preservar também as categorias originais. Apresentar matrículas e o indicador anual de saída por rede e modalidade, com contagens e denominadores.

A definição de evasão anual deve ser fechada na Fase 1 com o material do evento. QT_SIT_DESVINCULADO é uma contagem de situação de vínculo. Sua divisão por QT_MAT não é automaticamente uma probabilidade de evasão da população exposta.

Se o evento fornecer fórmula específica, aplicá-la e documentar o universo. Se não fornecer, apresentar uma medida operacional explícita de desligamento no ano: vínculos desvinculados e transferidos, quando a definição de saída do curso incluir transferência, divididos pelo total de vínculos não falecidos observados naquele ano. Chamar essa medida de proporção anual de saída do curso, explicando seu alcance e distinguindo-a da TDA longitudinal.

O total operacional pode ser reconstruído pelas situações mutuamente exclusivas do vínculo, após conferir o dicionário. Se QT_MAT já incluir cursando e formado, não somar QT_CONC novamente. Documentar o tratamento de trancados, transferidos e falecidos. Sem confirmação da composição, publicar as contagens e manter a taxa como não validada até resolver a regra.

Uma fórmula baseada no estoque de matrículas do ano anterior é outra metodologia e exige consistência entre estoques e fluxos. Para calcular 2021 dessa forma, seriam necessários dados de 2020. Não trocar a metodologia no meio da série.

Identificar um ano atípico pela variação em pontos percentuais e pelo volume associado, comparando categorias e a cobertura. Uma mudança pode refletir composição dos cursos ou revisão de dados. Com quatro anos, apresentar a evidência descritiva e investigar hipóteses sem atribuir causa.

Visualização: séries 2021 a 2024, em painéis por rede e modalidade. Resposta final: como o indicador e as matrículas variam e qual ano apresenta mudança mais pronunciada.

P4 Qualidade retém

Selecionar CPC 2021 a 2023. Manter a edição no fato e criar uma seleção com uma linha por curso. Para uma fotografia da trajetória até 2024, utilizar a edição disponível mais recente até esse limite. Registrar o ano da avaliação, que não se confunde com a data de publicação.

Separar cursos sem conceito, não avaliados e sem correspondência de chave. Não transformar essas condições em CPC zero. Antes da análise, apresentar taxa de junção por cursos e por alunos ou denominadores da trajetória. Os cursos avaliados em cada ciclo não necessariamente representam todas as áreas.

Comparar desistência no mesmo tempo relativo entre faixas do CPC. Examinar a associação com o conceito contínuo, se disponível, e repetir a comparação por área, rede e modalidade. Mostrar número de cursos, base analisada e diferença de taxas. Evitar uma correlação calculada em linhas repetidas de curso ao longo de vários anos como se fossem observações independentes.

Responder também o que mais se associa à trajetória usando diferenças por área, modalidade, rede e coorte. Um modelo exploratório com controles pode complementar a comparação se houver amostra e tempo suficientes, mas a análise estratificada já deve estar concluída antes disso.

O CPC escolhido pode ter sido medido após grande parte das desistências. Portanto, o cruzamento permite descrever associação entre qualidade observada e trajetória, sem provar que a qualidade produziu a retenção. Cursos sem correspondência não desaparecem do total da trajetória.

Visualização: gráfico de associação e taxas por faixa, com cobertura e filtros. Resposta final: direção e tamanho da associação, diferenças entre perfis e limitações.

P5 O funil das licenciaturas

Selecionar licenciaturas na trajetória e relacionar seus códigos com o Enade das Licenciaturas de 2025. Conferir o universo de participantes, resultados válidos e os padrões de proficiência definidos na edição. Usar as porcentagens oficiais ou reconstruí-las a partir das contagens e classificações previstas no leiaute.

Se houver contagens de não proficientes e de proficientes nos padrões publicados, a porcentagem de proficiência será o total de proficientes dividido pelo total de participantes com resultado válido. Inscritos, participantes e resultados válidos podem ter números diferentes. A agregação usa os participantes válidos como peso.

A trajetória até 2024 e o Enade 2025 não acompanham a mesma turma. Apresentar duas etapas relacionadas pelo curso: primeiro, quanto das coortes de licenciatura desiste ou conclui; depois, qual a proficiência observada entre os avaliados de 2025. Identificar os anos e as populações em cada painel.

Não apresentar o produto de TCA por proficiência de 2025 como quantidade observada de ingressantes que se formaram proficientes. Esse número exigiria ligação entre os mesmos indivíduos ou uma hipótese explícita de simulação. O dashboard deve preservar a separação dos universos.

Visualização: dois painéis vinculados por curso, com desistência e conclusão na trajetória e proficiência entre avaliados em 2025. Resposta final: dimensão da perda nas licenciaturas e desempenho dos avaliados, incluindo cobertura do cruzamento.

11 Bônus e recomendações de negócio

B2 Financiamento e permanência

Usar cursos privados do Censo 2021 a 2024. Conferir se os campos de FIES e ProUni contam ingressantes ou matrículas. O denominador deve corresponder à mesma população e ao mesmo ano. Por exemplo, um campo de ingressantes com FIES usa o total de ingressantes, não o total de matrículas.

Calcular participações separadas de FIES, ProUni integral e ProUni parcial quando disponíveis. Não somar programas para obter uma quantidade de pessoas sem confirmar que as categorias são mutuamente exclusivas. Cruzar a participação do financiamento com o indicador de saída no nível curso e ano, usando os mesmos critérios territoriais de P3.

Comparar cursos semelhantes por área e modalidade. Apresentar a cobertura dos campos e a mudança de composição anual. A relação agregada não informa se os alunos financiados são aqueles que permaneceram ou saíram. A conclusão deve descrever a associação entre perfil de financiamento e saída do curso.

B1 Oferta presencial e população jovem

Se houver tempo, obter população municipal de 18 a 24 anos na tabela 9514 do SIDRA ou na fonte oficial indicada pela organização. Conferir variáveis, categorias de idade e ano efetivamente disponíveis. Guardar a resposta JSON e os parâmetros consultados.

Selecionar apenas uma combinação de sexo e outros recortes que represente o total necessário. Não somar a categoria Total junto com suas subcategorias. Agregar somente as idades de 18 a 24 anos.

Fórmula: vagas presenciais por 100 jovens = 100 vezes vagas presenciais do município divididas pela população de 18 a 24 anos. Quando o Censo for de 2024 e a população do Censo Demográfico de 2022, identificar os dois anos. O indicador combina períodos diferentes e não estima demanda ou acessibilidade individual.

Usar a lista de todos os municípios de Mato Grosso como base e fazer LEFT JOIN com a oferta. A ausência real de oferta confirmada deve produzir zero vagas. Ausência de município por erro de chave deve produzir dado ausente, não zero. Para denominador zero ou ausente, a razão permanece nula.

As recomendações finais devem relacionar achado, ação, responsável sugerido e indicador de acompanhamento. Exemplos de ações condicionais são apoio nos anos com maior perda, revisão de processos nas áreas prioritárias e investigação de financiamento em cursos comparáveis. Formular a ação somente depois de validar o achado, sem inventar economia ou redução de evasão.

12 Qualidade e critérios de publicação

Regra	Critério proposto	Ação em caso de falha
Colunas essenciais	Presentes e mapeadas por edição	Interromper aquela fonte
Chave do fato	Sem duplicidade no nível confirmado	Investigar o nível de detalhe
Contagens	Não negativas	Rejeitar ou investigar a linha
Percentuais	Entre 0 e 100	Conferir escala e origem
Soma TDA TCA TAP	Próxima de 100 na precisão da fonte	Investigar denominadores e arredondamento
Tempo da trajetória	Ano de referência igual ou posterior à coorte	Bloquear registro inconsistente
Evolução acumulada	Conferida com anos consecutivos	Identificar revisão ou lacuna
Junção	Sem aumento indevido de linhas ou bases	Bloquear o mart afetado
Cobertura	Medida por curso e por base de alunos	Mostrar exclusões e limitar interpretação
Reexecução	Mesmo conteúdo com as mesmas entradas	Corrigir idempotência
Células pequenas	Nenhuma célula de alunos abaixo do limite publicado	Reagrupar ou suprimir
Exportações	Mesmo conjunto e mesma execução	Refazer o pacote completo

Definir a tolerância da soma das taxas a partir das casas decimais publicadas. Por exemplo, tolerância de 0,2 ponto percentual pode servir como ponto inicial para uma fonte com uma casa decimal, mas deve ser confirmada. Não arredondar antecipadamente para fazer a soma fechar.

Para a taxa de junção, medir registros ou cursos da base esquerda com correspondência divididos pelo total elegível da base esquerda. Medir também a fração de alunos ou denominadores coberta.

Não estabelecer uma cobertura universal de 95% como exigência oficial: CPC e Enade têm universos avaliados próprios. Comparar com a cobertura esperada e mostrar as lacunas.

Antes e depois de cada junção, comparar quantidade de linhas, número de chaves distintas e soma dos denominadores. Construir uma relação CPC ou Enade com uma linha por curso no recorte antes de juntá-la à trajetória. Manter LEFT JOIN quando o objetivo for preservar a população original.

O evento penaliza a exposição de células com menos de dez alunos. Aplicar a regra antes de exportar, inclusive para CSV público, tabelas de download, tooltips e PDF. Conferir tanto a base quanto as contagens de resultados que possam ser inferidas pelas porcentagens. Reagrupar em área ou rede quando necessário e usar supressão complementar quando um total permitir reconstruir uma célula escondida.

Vagas e população municipal de B1 não são contagens de alunos de uma turma. A regra de divulgação deve preservar o significado da medida e a norma do evento. A lista de municípios sem oferta pode apresentar zero vagas, depois de validar a cobertura territorial.

Cada indicador publicado terá um registro de metodologia com pergunta, fonte, período, população, filtros, numerador, denominador, unidade, ponderação, cobertura e política de supressão. O relatório de qualidade deve separar falhas críticas de alertas explicativos. Uma inconsistência que afete o indicador bloqueia sua publicação.

13 Dashboard e Fase 3 até 17h

Organizar o dashboard em páginas que acompanham as perguntas. Na abertura, explicar o recorte e mostrar a composição da trajetória. Nas demais páginas, detalhar áreas, perfis, qualidade e licenciaturas. A última página reúne financiamento e recomendações. Uma área de metodologia apresenta fontes e cobertura.

Página	Pergunta	Elementos principais
Visão geral	P1	Composição, linha anual e maior aumento da desistência
Cursos e áreas	P2	Rankings e coortes no mesmo tempo relativo
Rede e modalidade	P3	Séries anuais e matrículas
Qualidade	P4	CPC, associação e cobertura
Licenciaturas	P5	Trajetória e proficiência em painéis distintos
Financiamento	B2	Participações e comparação de cursos
Metodologia	Todas	Definições, períodos, fontes e limitações

Filtros devem atuar somente sobre as fontes e populações pertinentes. Um filtro de coorte não pode mudar o Enade 2025 como se ele tivesse esse atributo. Utilizar taxas em percentuais, variações em pontos percentuais e contagens com unidades claras. Evitar um único gráfico de funil que misture populações incompatíveis.

Horário	Atividade	Resultado esperado
14h15 a 14h50	Concluir B2 e conferir P1 a P5	Seis respostas verificadas
14h50 a 15h20	Revisar dashboard e proteger exportações	Produto com metodologia e filtros coerentes
15h20 a 15h45	Publicar e testar fora da máquina principal	Acesso pela máquina da banca ou equivalente
15h45 a 16h15	Executar a reprodução e os testes finais	Evidências de conteúdo e idempotência
16h15 a 16h35	Gerar PDF, conferir links e concluir documentação	Contingência pronta e README completo
16h35 a 16h50	Ensaiar pitch e congelar funcionalidades	Apresentação dentro dos cinco minutos
16h50 a 17h	Commit final, envio e conferência de acesso	Entrega confirmada antes do prazo

Tratar 16h50 como meta para o último commit. Após o congelamento, alterar somente falhas que comprometam resultado ou acesso. Reservar o intervalo final para envio e comprovação da entrega. A apresentação ocorre depois das 17h, mas os materiais que serão avaliados precisam estar disponíveis no prazo.

14 Repositório e execução reproduzível

Caminho	Conteúdo esperado
README.md	Objetivo, instalação, execução, perguntas e links
requirements.txt	Dependências nas versões testadas
.env.example	Nomes das variáveis sem credenciais
.gitignore	data, segredos, ambiente virtual e arquivos temporários
config	Fontes, leiautes e filtros por edição
docs/estrategia.md	Exploração e decisões da Fase 1
docs/arquitetura.md	Camadas, fatos, chaves e carga
docs/metricas.md	Fórmulas, universos e ponderação
src	Download, ingestão, validação e pipeline
sql	Criação de esquemas, transformações, marts e checagens
dashboard	Aplicação e configuração de publicação
outputs	Somente agregados preparados para divulgação
prompts	Conversas com IA e índice obrigatório

A interface a implementar pode ser python -m src.pipeline --config config/fontes.yml. Prever modos para validar, reprocessar e exportar. Isso é uma especificação para o projeto, não um comando já implementado neste documento. O pipeline deve executar downloads ou verificação dos arquivos, carga, transformação, testes e exportação nessa ordem.

O README explica como instalar PostgreSQL e Python, criar o banco e os esquemas, configurar as variáveis, obter as bases oficiais e executar o pipeline. Em seguida, explica como abrir o dashboard, onde estão as respostas e como repetir as checagens. Registrar requisitos de espaço, versões e tempo observado de execução.

Os dados brutos ficam fora do Git. Os resultados públicos pequenos podem ser versionados em outputs, desde que tenham sido agregados e protegidos. Publicar o manifesto de entradas para permitir comparação de versões. Não registrar dumps, senhas ou linhas rejeitadas com informações que violem a regra de células pequenas.

Testar a reprodução com outro integrante, a partir de um ambiente limpo ou de um banco separado. O teste não pode depender de etapas manuais omitidas. Registrar commit, manifesto, tempo de execução e comparação dos resultados.

Cada sessão de IA deve ser guardada integralmente em prompts, ou representada pelo link de compartilhamento permitido pela organização. Usar o padrão AAAA-MM-DD_HHMM_ferramenta_tema.md. O índice informa responsável, fase, objetivo e o que foi adotado, conferido ou corrigido. Registrar especialmente decisões sobre ponderação, temporalidade, duplicação de junções e revisão das fórmulas.

15 Pitch final e alinhamento com a avaliação

O pitch final tem cinco minutos de apresentação e três de perguntas. Apresentar respostas diretas, com os números realmente encontrados, sem preencher lacunas com exemplos fictícios. O público deve entender o que os indicadores mostram e qual decisão eles podem apoiar.

Tempo aproximado	Conteúdo
00:00 a 00:35	Pergunta central, recorte e fontes
00:35 a 01:25	P1, composição da coorte e momento de maior perda
01:25 a 02:10	P2, áreas e cursos prioritários
02:10 a 02:50	P3, rede, modalidade e variação anual
02:50 a 03:30	P4, associação entre CPC e trajetória
03:30 a 04:10	P5, licenciaturas e proficiência de 2025
04:10 a 04:40	B2 e recomendação apoiada nos resultados
04:40 a 05:00	Limitações essenciais e ação proposta

A coluna de tempo usa minutos e segundos de apresentação. Preparar respostas sobre por que PostgreSQL, como a reexecução evita duplicação, qual o denominador das taxas, como a equipe preservou a granularidade, quantos cursos ficaram sem correspondência e por que associação não prova causa.

Rubrica	Peso na nota final	Evidência prioritária
Técnica F1	15%	Ambiente, exploração e estratégia justificadas
Técnica F2	20%	Ingestão, idempotência, qualidade e protótipo
Técnica F3	25%	Reprodução, corretude, documentação e domínio do uso de IA
Negócio	40%	Cinco respostas, um bônus, clareza e recomendação

O critério Respondeu às perguntas vale 30 pontos da rubrica de negócio. Cinco perguntas e ao menos um bônus são necessários para alcançar Excelente nesse critério. Idempotência vale 20 pontos da F2. Uso de IA e domínio técnico vale 25 pontos da F3. Essas evidências precisam aparecer no repositório e ser defendidas pela equipe.

As regras destacam penalidades por células com menos de dez alunos, acesso indisponível, ausência de contingência e excesso de tempo do pitch. As notas do slide de penalidades também citam punição por linguagem causal com dados agregados. Confirmar os detalhes no cronograma e nas rubricas oficiais. A entrega final fora do prazo, plágio e uso de dados não públicos podem causar desclassificação.

16 Riscos e decisões de contingência

Risco	Sinal de alerta	Decisão operacional
Banco indisponível	Sem conexão às 8h30	Acionar PostgreSQL alternativo autorizado
Download demorado	Fonte crítica sem transferência concluída	Priorizar trajetória, Censo e qualidade e conferir espelho oficial permitido
Mudança de leiaute	Colunas ou categorias divergentes	Criar mapeamento por edição e bloquear conversão automática
Chave sem correspondência	Cobertura abaixo do esperado	Preservar cursos sem junção e limitar o universo da análise
Taxa de P3 indefinida	Denominador sem confirmação	Resolver com dicionário e organização antes da publicação
Linha duplicada na junção	Base ou linhas aumentam	Corrigir chave e seleção temporal antes do mart
B2 inviável	Financiamento ausente ou sem universo claro	Priorizar B1 com fonte e recorte validados
Aplicação sem acesso	Teste externo falha até 15h45	Usar HTML autônomo preparado e PDF obrigatório
Base com células pequenas	Exportação permite inferência	Reagrupar e suprimir antes de divulgar

Risco	Sinal de alerta	Decisão operacional
Atraso final	Documentação incompleta às 16h15	Congelar escopo, concluir evidências e enviar antes das 17h

Às 12h, verificar se P1 a P3 já têm caminho de cálculo validado e se qualidade e Enade foram obtidos. Às 14h15, o protótipo precisa mostrar as perguntas obrigatórias. Às 15h45, o formato de apresentação deve estar definido e testado. Às 16h15, nenhuma nova análise passa à frente da documentação, contingência e reprodução.

17 Checklist de conclusão e evolução

1. P1 a P5 possuem resultado, fonte, período, população e interpretação.
2. Pelo menos um bônus tem cálculo e conclusão completos.
3. As comparações de coortes usam o mesmo tempo de acompanhamento.
4. As taxas agregadas têm denominadores e pesos documentados.
5. Censo, trajetória e Enade preservam suas populações e períodos.
6. Junções não alteram indevidamente linhas ou bases.
7. A repetição das cargas reproduz os mesmos fatos e saídas.
8. Os arquivos públicos respeitam a regra de células pequenas.
9. O dashboard abre fora da máquina principal da equipe.
10. O PDF de contingência corresponde à versão final.
11. O repositório público, os links e os convites foram conferidos.
12. README, metodologia e prompts estão completos.
13. O pitch foi ensaiado dentro de cinco minutos.
14. O commit e o envio final ocorreram antes das 17h.

Após o evento, uma evolução em duas a quatro semanas pode automatizar atualização das fontes, parametrizar novas edições e adicionar testes por leiaute. Uma etapa posterior pode oferecer comparação entre estados, ampliar o contexto municipal e investigar associações com modelos adequados. Definir frequência de atualização, armazenamento e infraestrutura depois de medir o volume real e discutir o uso do produto.

18 Referências e materiais operacionais

Apresentação fornecida: DataHack_Abertura_Rota_do_Diploma.pptx. Os slides e suas notas fundamentam as perguntas, fontes, cronograma, entregas, rubricas e penalidades deste roadmap.

Materiais operacionais citados pela organização: fontes_dados.html, dicionario_dados.html, amostras_top10.html, cronograma_rubrica.html, rubricas.json e rubricas.csv. Devem orientar downloads, mapeamentos e confirmação das regras no início do evento.

INEP. Indicadores de Trajetória da Educação Superior. https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/indicadores-educacionais/indicadores-de-trajetoria-da-educacao-superior

INEP. Metodologia de Cálculo dos Indicadores de Fluxo da Educação Superior. https://download.inep.gov.br/informacoes_estatisticas/indicadores_educacionais/2017/metodologia_indicadores_trajetoria_curso.pdf

INEP. Microdados do Censo da Educação Superior. https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/microdados/censo-da-educacao-superior

INEP. Manual de preenchimento do Censo da Educação Superior 2023, módulo aluno. https://download.inep.gov.br/educacao_superior/censo_superior/manuais_e_instrucoes/manual_de_aluno_2023.pdf

INEP. Indicadores de Qualidade da Educação Superior 2025, Conceito Enade Licenciaturas. https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/indicadores-educacionais/indicadores-de-qualidade-da-educacao-superior/2025

PostgreSQL. COPY. https://www.postgresql.org/docs/current/sql-copy.html

PostgreSQL. INSERT e ON CONFLICT. https://www.postgresql.org/docs/current/sql-insert.html

PostgreSQL. Populating a Database. https://www.postgresql.org/docs/current/populate.html

PostgreSQL. Transactions. https://www.postgresql.org/docs/current/tutorial-transactions.html

As definições operacionais devem seguir a documentação da edição efetivamente utilizada. O roadmap determina as etapas e os critérios de conclusão. A exploração dos arquivos oficiais confirma o mapeamento exato, os universos e as fórmulas antes da divulgação dos resultados.